召回的难点

召回的依据

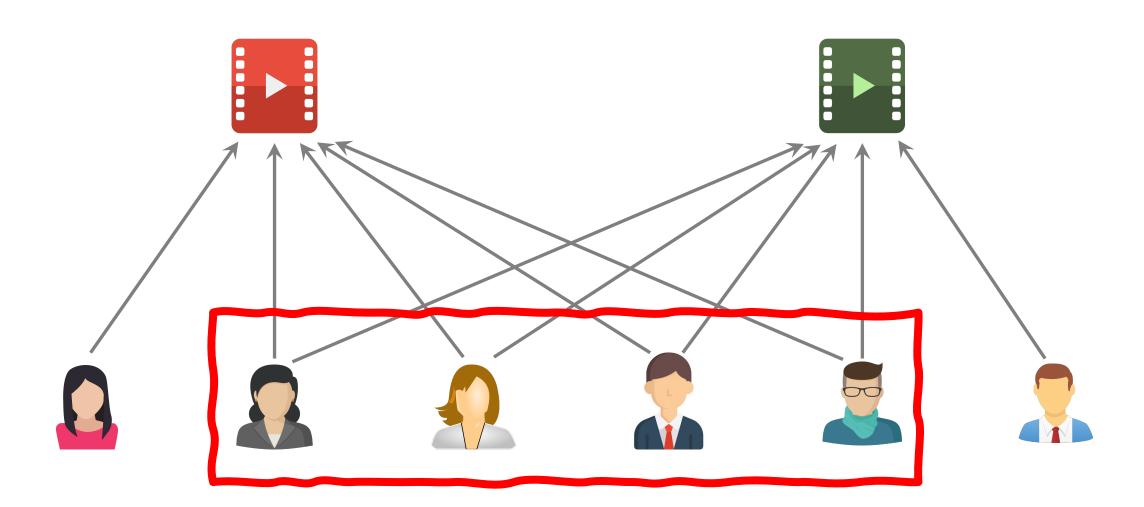
- ✓自带图片、文字、地点。
- ✓ 算法或人工标注的标签。
- ×没有用户点击、点赞等信息。
- ×没有笔记 ID embedding。

冷启召回的困难

- 缺少用户交互,还没学好笔记 ID embedding,导致双塔模型效果不好。
- · 缺少用户交互,导致 ItemCF 不适用。

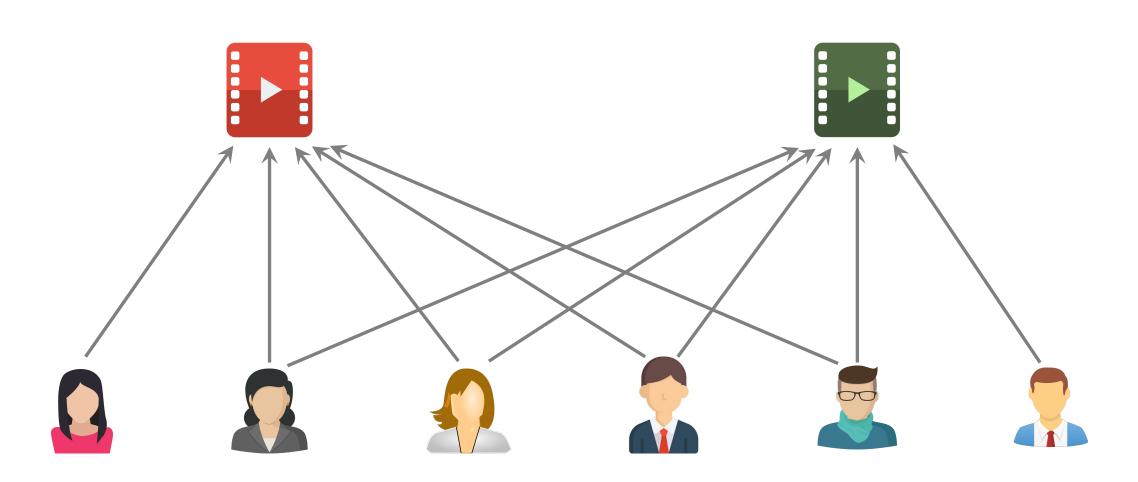
冷启召回的困难

ItemCF 不适用于物品冷启动



冷启召回的困难

ItemCF 不适用于物品冷启动

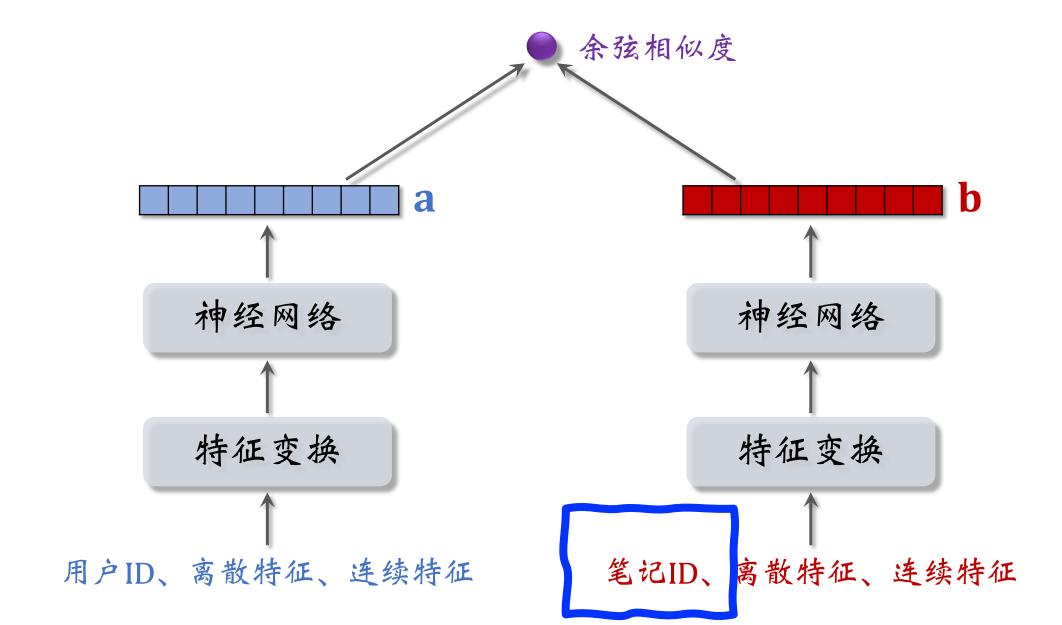


召回通道

- × ItemCF召回(不适用)
- ② 双塔模型(改造后适用)✓ 类目、关键词召回(适用)
- ✓ 聚类召回(适用)
- ✓ Look-Alike召回 (适用)

双塔模型

双塔模型



ID Embedding

改进方案 1:新笔记使用 default embedding。

- 物品塔做 ID embedding 时,让所有新笔记共享一个 ID,而不是用自己真正的 ID。
- Default embedding: 共享的 ID 对应的 embedding 向量。
- 到下次模型训练的时候,新笔记才有自己的 ID embedding 向量。

ID Embedding

改进方案 1:新笔记使用 default embedding。

改进方案 2:利用相似笔记 embedding 向量。

- · 查找 top k 内容最相似的高曝笔记。
- 把 k 个高曝笔记的 embedding 向量取平均,作为新笔记的 embedding。

多个向量召回池

- 多个召回池,让新笔记有更多曝光机会。
 - 1 小时新笔记,
 - 6 小时新笔记,
 - 24 小时新笔记,
 - 30 天笔记。
- 共享同一个双塔模型,那么多个召回池不增加训练的代价。

类目召回

用户画像

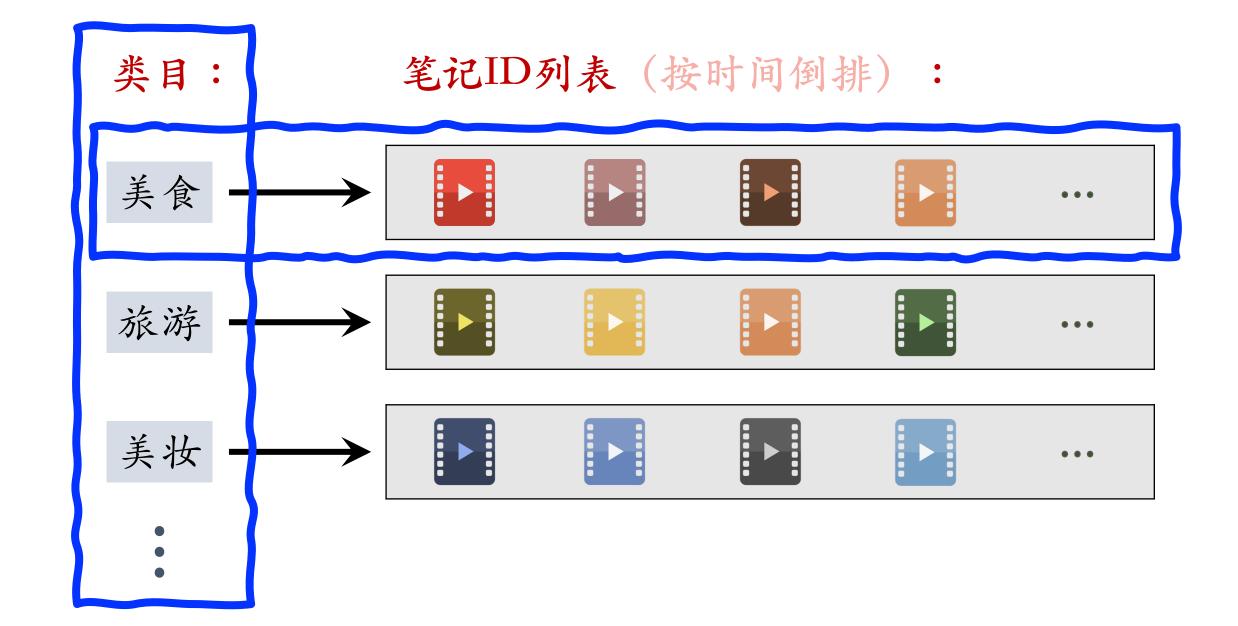
• 感兴趣的类目:

美食、科技数码、电影……

• 感兴趣的关键词:

纽约、职场、搞笑、程序员、大学……

基于类目的召回



基于类目的召回

• 系统维护类目索引:

类目 → 笔记列表 (按时间倒排)

• 用类目索引做召回:

用户画像 → 类目 → 笔记列表

•取回笔记列表上前 k 篇笔记(即最新的 k 篇)。

基于关键词的召回

• 系统维护关键词索引:

关键词 > 笔记列表 (按时间倒排)

•根据用户画像上的关键词做召回。

缺点

- •缺点1:只对刚刚发布的新笔记有效。
 - 取回某类目/关键词下最新的 k 篇笔记。
 - 发布几小时之后,就再没有机会被召回。
- 缺点2:弱个性化,不够精准。

- × ItemCF召回(不适用)
- ② 双塔模型(改造后适用)✓ 类目、关键词召回(适用)
- ✓ 聚类召回(适用)
- ✓ Look-Alike召回 (适用)